


Задачи машинного обучения

Быстренина Ирина Евгеньевна, к.п.н., доцент
Bystrenina.IE@rea.ru



КЛАССИФИКАЦИЯ

Классификация

Классификация — это задача прогнозирования категориальных переменных на основе данных. В результате решения задачи классификации обнаруживаются признаки, которые характеризуют группы объектов исследуемого набора данных — классы; по этим признакам новый объект можно отнести к тому или иному классу.

Примеры классификации

- Например, можно предсказать, кто из клиентов фирмы является потенциальным покупателем определенного товара, а кто - нет, кто воспользуется услугой фирмы, а кто - нет, и т.д. Этот тип задач относится к задачам бинарной классификации, в них зависимая переменная может принимать только два значения (например, да или нет, 0 или 1).
- Другой вариант классификации возникает, если зависимая переменная может принимать значения из некоторого множества предопределенных классов. Например, когда необходимо предсказать, какую марку автомобиля захочет купить клиент. В этих случаях рассматривается множество классов для зависимой переменной.


Рассмотрим задачу классификации

Имеется база данных о клиентах туристического агентства с информацией о возрасте и доходе за месяц. Есть рекламный материал двух видов: более дорогой и комфортный отдых и более дешевый, молодежный отдых. Соответственно, определены два класса клиентов: класс 1 и класс 2.

Задача. Определить, к какому классу принадлежит новый клиент и какой из двух видов рекламных материалов ему стоит отсылать.

Код клиента	Возраст	Доход	Класс
1.	18	25	1
2	22	100	1
3	30	70	1
4	32	120	1
5	24	15	2
6	25	22	1
7	32	50	2
8	19	45	2
9	22	75	1
10	40	90	2

Для наглядности представим нашу базу данных в двухмерном измерении (возраст и доход), в виде множества объектов, принадлежащих классам 1 (оранжевая метка) и 2 (серая метка). На рисунке приведены объекты из двух классов.



Решение нашей задачи будет состоять в том, чтобы определить, к какому классу относится новый клиент, на рисунке обозначенный белой меткой.

Процесс классификации

Цель процесса классификации состоит в том, чтобы построить модель, которая использует прогнозирующие атрибуты в качестве входных параметров и получает значение зависимого атрибута. Процесс классификации заключается в разбиении множества объектов на классы по определенному критерию.

Набор исходных данных (или выборку данных) разбивают на два множества: обучающее и тестовое.

Обучающее множество (training set) - множество, которое включает данные, используемые для обучения (конструирования) модели. Такое множество содержит входные и выходные (целевые) значения примеров. Выходные значения предназначены для обучения модели.

Тестовое (test set) множество также содержит входные и выходные значения примеров. Здесь выходные значения используются для проверки работоспособности модели.

Процесс классификации состоит из двух этапов:

конструирования модели и ее использования.


1. Конструирование модели: описание множества predetermined классов.

- Каждый пример набора данных относится к одному predetermined классу.
- На этом этапе используется обучающее множество, на нем происходит конструирование модели.
- Полученная модель представлена классификационными правилами, деревом решений или математической формулой.


2. Использование модели: классификация новых или неизвестных значений.

- Оценка правильности (точности) модели.
 1. Известные значения из тестового примера сравниваются с результатами использования полученной модели.
 2. Уровень точности - процент правильно классифицированных примеров в тестовом множестве.
 3. Тестовое множество, т.е. множество, на котором тестируется построенная модель, не должно зависеть от обучающего множества.
- Если точность модели допустима, возможно использование модели для классификации новых примеров, класс которых неизвестен.

1. Процесс классификации. Конструирование модели



2. Процесс классификации. Использование модели




Методы, применяемые для решения задач классификации

Для классификации используются различные методы. Основные из них:


- классификация с помощью деревьев решений;
- классификация при помощи искусственных нейронных сетей;
- классификация методом опорных векторов;
- статистические методы, в частности, линейная регрессия;
- классификация при помощи метода ближайшего соседа;
- классификация при помощи генетических алгоритмов.

Решение задачи классификации методом линейной регрессии



Решение задачи классификации методом деревьев решений

```
if X > 5 then grey
  else if Y > 3 then orange
    else if X > 2 then grey
      else orange
```



Решение задачи классификации методом нейронных сетей



Матрица ошибок (Confusion matrix) (бинарная классификация)

Объекты с меткой
«1» будем называть
«**положительными**»

$y = 1$
 $x \in \omega_1$

Реальность

$y = 0$
 $x \in \omega_2$

Объекты с меткой
«0» будем называть
«**отрицательными**»

Предсказания

$a(x) = 1$
 $x \in \omega_1$

$a(x) = 0$
 $x \in \omega_2$

**True Positive
(TP)**

**False Positive
(FP)**

**False Negative
(FN)**

**True Negative
(TN)**

TP – предсказание (прогноз) совпадает с реальностью, т.е. модель дала правильный прогноз, наблюдаемое и истинное положение $x \in \omega_1$ совпадают.

FP – ошибка **первого** рода. Когда предсказанное (наблюдаемое) значение x попадает в класс ω_1 , а истинное его положение в классе ω_2 .

FN – ошибка **второго** рода. Когда предсказанное (наблюдаемое) значение x попадает в класс ω_2 , а истинное его положение в классе ω_1 .

TN – предсказание (прогноз) совпадает с реальностью, т.е. модель дала правильный прогноз, наблюдаемое и истинное положение $x \in \omega_2$ совпадают.

Критерии качества в задаче классификации (меры качества)

Алгоритм возвращает произвольное вещественное число, которое с помощью порога переводится в бинарный ответ $a(x) = \{f(x) > t\}$.

1. Доля правильных ответов алгоритма (accuracy), доля правильных классификаций

$$\text{accuracy} = \frac{TP+TN}{TP+FP+FN+TN}$$

Недостатки: не учитывается дисбаланс классов (численность классов), а также не учитывается цена ошибки на объектах разных классов, т.е. его порог t меньше минимального значения прогноза $f(x)$ на выборке или больше максимального значения, то доля правильных ответов будет равна доле положительных и отрицательных ответов соответственно.

Пример – оценить работу SpamAssassin

Имеется 100 писем (90 не спам писем и 10 спам писем).

Классификатор классифицирует

90 не спам писем	
80 писем верно	10 писем не верно

10 спам писем	
5 писем верно	5 писем не верно

$$\text{accuracy} = \frac{80+5}{80+5+10+5} = 0,85 = 85\%$$

Доля правильных ответов не несет сама по себе никакой информации о работе алгоритма $a(x)$.

Более информативные критерии

2. Precision (точность)

Доля объектов, выделенных классификатором как правильные (положительные), действительно являются правильными (положительными)

$$\text{precision} = \frac{TP}{TP + FP}$$

3. Recall (полнота)

показывает, какая часть положительных объектов была выделена классификатором

$$\text{recall} = \frac{TP}{TP + FN}$$

Пример – Рассмотрим задачу предсказания реакции клиентов магазина продажи мобильных телефонов на звонок с предложением приобрести новое устройство.

Пусть ответ

$y = 1$ – клиент приобретет новый телефон после звонка из магазина.

$y = 0$ – клиент не приобретет новый телефон.

Основная цель: Планируется обзванивать только тех клиентов, для которых построенный классификатор выдаст $a(x)=1$.

Выводы:

1. Если классификатор имеет высокую точность, то почти все клиенты, которым будет сделано предложение о покупке, откликнутся на него.
2. Если классификатор имеет высокую полноту, то предложение о покупке будет сделано практически всем клиентам, готовым откликнуться на него.

Замечание: С помощью изменения величины порога t можно регулировать точность и полноту!!!

Если в классификаторе $a(x) = \{f(x) > t\}$ выбрать значение порога t достаточно большим, то классификатор отнесет к «положительному» классу небольшое число образов, что соответствует высокой точности (precision) и низкой полноте (recall). При уменьшении значения t точность будет падать, а полнота расти.

4. F-мера

Гармоническое среднее точности и полноты.

$$F = \frac{2}{\frac{1}{\text{recall}} + \frac{1}{\text{precision}}} = \frac{2 \cdot \text{recall} \cdot \text{precision}}{\text{recall} + \text{precision}}$$

Замечание: использование среднего гармонического для точности и полноты намного предпочтительнее, чем использование среднего арифметического.

Например: Допустим алгоритм относит все объекты к положительному классу, т.е. $a(x)=1$. В этом случае $\text{recall}=1$, а $\text{precision} \ll 1$. При этом среднее арифметическое будет больше $1/2$, что не допустимо!

Пример с метриками классификации на языке python

```
[ ] import matplotlib.pyplot as plt
import numpy as np
from sklearn.datasets import load_digits
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report, confusion_matrix, ConfusionMatrixDisplay
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.preprocessing import label_binarize
```

```
[ ] %matplotlib inline
```

```
[ ] x, y = load_digits(return_X_y=True)
```



x

```
array([[ 0.,  0.,  5., ...,  0.,  0.,  0.],
       [ 0.,  0.,  0., ..., 10.,  0.,  0.],
       [ 0.,  0.,  0., ..., 16.,  9.,  0.],
       ...,
       [ 0.,  0.,  1., ...,  6.,  0.,  0.],
       [ 0.,  0.,  2., ..., 12.,  0.,  0.],
       [ 0.,  0., 10., ..., 12.,  1.,  0.]])
```



Пример с метриками классификации на языке python

```
[ ] y
```

```
array([0, 1, 2, ..., 8, 9, 8])
```

```
digits=load_digits()  
plt.gray()  
plt.matshow(digits.images[3])
```

```
<matplotlib.image.AxesImage at 0x7b4108ddc2e0>  
<Figure size 640x480 with 0 Axes>
```



Пример с метриками классификации на языке python

```
[ ] x_train, x_test, y_train, y_test=train_test_split(x, y, test_size=0.2, random_state=0)
```

```
[ ] scaler=StandardScaler()  
x_train=scaler.fit_transform(x_train)  
x_test=scaler.transform(x_test)
```

▶ x_train

```
→ array([[ 0.          , -0.33790435, -1.09141592, ...,  1.58325794,  
          3.53125595,  3.30213343],  
 [ 0.          ,  2.90642897,  1.41696421, ...,  1.58325794,  
          0.00595786, -0.18695903],  
 [ 0.          ,  0.74354009,  0.99890086, ..., -1.14493411,  
          -0.49765616, -0.18695903],  
 ...,  
 [ 0.          , -0.33790435, -0.04625753, ..., -1.14493411,  
          -0.49765616, -0.18695903],  
 [ 0.          , -0.33790435, -0.25528921, ..., -1.14493411,  
          -0.49765616, -0.18695903],  
 [ 0.          , -0.33790435,  0.16277415, ...,  0.73069792,  
          -0.49765616, -0.18695903]])
```

+ Kc

```
[ ] model=LogisticRegression(solver='liblinear', C=0.05, multi_class='ovr', random_state=0)  
model.fit(x_train, y_train)
```

```
→ LogisticRegression  
LogisticRegression(C=0.05, multi_class='ovr', random_state=0,  
                    solver='liblinear')
```

Пример с метриками классификации на языке python

```
[ ] x_test
```

```
array([[ 0.          , -0.33790435,  1.20793253, ...,  1.07172193,
         3.53125595,  4.46516425],
       [ 0.          ,  0.74354009,  2.04405924, ..., -0.97442211,
        -0.49765616, -0.18695903],
       [ 0.          ,  1.82498453,  1.62599589, ...,  1.58325794,
         3.53125595,  1.5575872 ],
       ...,
       [ 0.          ,  0.74354009,  0.78986918, ..., -0.4628861 ,
        -0.49765616, -0.18695903],
       [ 0.          , -0.33790435, -1.09141592, ...,  1.41274594,
         0.00595786, -0.18695903],
       [ 0.          , -0.33790435, -1.09141592, ...,  0.90120993,
        -0.49765616, -0.18695903]])
```

```
[ ] y_pred=model.predict(x_test)
```

```
y_pred
```

```
array([2, 8, 2, 6, 6, 7, 1, 9, 8, 5, 2, 8, 6, 6, 6, 6, 1, 0, 5, 8, 8, 7,
       8, 4, 7, 5, 4, 9, 2, 9, 4, 7, 6, 8, 9, 4, 3, 1, 0, 1, 8, 6, 7, 7,
       9, 0, 7, 6, 2, 1, 9, 6, 7, 9, 0, 0, 5, 1, 6, 3, 0, 2, 3, 4, 1, 9,
       2, 6, 9, 1, 8, 3, 5, 1, 2, 1, 2, 2, 9, 7, 2, 3, 6, 0, 5, 3, 7, 5,
       1, 2, 9, 9, 3, 1, 7, 7, 4, 8, 5, 8, 5, 5, 2, 5, 9, 0, 7, 1, 4, 7,
       3, 4, 8, 9, 7, 7, 8, 0, 1, 5, 2, 5, 3, 4, 1, 7, 0, 6, 1, 5, 9, 9,
       9, 5, 9, 9, 5, 7, 5, 6, 2, 8, 6, 7, 6, 1, 5, 1, 5, 9, 9, 1, 5, 3,
       6, 1, 8, 9, 7, 7, 6, 7, 6, 5, 6, 0, 8, 8, 9, 3, 6, 1, 0, 4, 1, 6,
       3, 8, 6, 7, 4, 9, 6, 3, 0, 3, 3, 0, 7, 7, 5, 7, 8, 0, 7, 8, 9,
       6, 4, 5, 0, 1, 4, 6, 4, 3, 3, 0, 9, 5, 9, 2, 1, 4, 2, 1, 6, 8, 9,
       2, 4, 9, 3, 7, 6, 2, 3, 3, 1, 6, 9, 3, 6, 3, 2, 2, 0, 7, 6, 1, 1,
       3, 7, 2, 7, 8, 5, 5, 7, 5, 3, 2, 7, 2, 7, 5, 5, 7, 0, 9, 1, 6, 5,
       9, 7, 4, 3, 8, 0, 3, 6, 4, 6, 3, 1, 6, 8, 8, 8, 4, 6, 7, 5, 2, 4,
```

Пример с метриками классификации на языке python

```
[ ] y_pred_prob=model.predict_proba(x_test)
```

```
[ ] model.score(x_train, y_train)
```

```
⇒ 0.964509394572025
```

```
[ ] model.score(x_test, y_test)
```


```
⇒ 0.9416666666666667
```

```
[ ] cm=confusion_matrix(y_test, y_pred)
```

```
[ ] disp=ConfusionMatrixDisplay(confusion_matrix=cm)
```

```
▶ disp.plot()
```

```
⇒ <sklearn.metrics._plot.confusion_matrix.ConfusionMatrixDisplay at 0x7b4108a14b50>
```



Пример с метриками классификации на языке python

```
print(classification_report(y_test, y_pred))
```

	precision	recall	f1-score	support
0	0.96	1.00	0.98	27
1	0.89	0.91	0.90	35
2	0.94	0.92	0.93	36
3	0.88	0.97	0.92	29
4	1.00	0.97	0.98	30
5	0.97	0.97	0.97	40
6	0.98	0.98	0.98	44
7	0.91	1.00	0.95	39
8	0.94	0.85	0.89	39
9	0.95	0.88	0.91	41
accuracy			0.94	360
macro avg	0.94	0.94	0.94	360
weighted avg	0.94	0.94	0.94	360


Кросс-валидация. Особенности применения

Оценка точности классификации может проводиться при помощи кросс-проверки.

Кросспроверка (Cross-validation) - это процедура оценки точности классификации на данных из тестового множества, которое также называют кросс-проверочным множеством. Точность классификации тестового множества сравнивается с точностью классификации обучающего множества. Если классификация тестового множества дает приблизительно такие же результаты по точности, как и классификация обучающего множества, считается, что данная модель прошла кросс-проверку. Разделение на обучающее и тестовое множества осуществляется путем деления выборки в определенной пропорции, например обучающее множество - две трети данных и тестовое - одна треть данных.

K-fold кросс-валидация

1. Данные разбиваются на k блоков примерно одинакового размера.
2. Модель обучается на $k-1$ части обучающей выборки.
3. Модель тестируется на части обучающей выборки, которая не участвовала в обучении.
4. Каждая из k частей единожды используется в обучении.



РЕГРЕССИЯ


- Простая линейная регрессия
 - Понятие регрессии
 - Что такое линейная регрессия и подбор регрессионной прямой
 - Метод наименьших квадратов
- Многомерная линейная регрессия
 - Матричный подход
 - Примеры построения регрессионной модели
- Более сложные модели линейной регрессии
 - Полиномиальные модели
 - Неполиномиальные модели

Простая линейная регрессия

Простая линейная регрессия

Задача 1: (зависимость между ростом и весом)

Точечная диаграмма (рост и вес взрослых людей)



X – рост взрослого человека, дюймы

Y – вес взрослого человека, фунты

1 дюйм = 25,4 мм

1 фунт = 0,45 кг

Основное предположение: зависимость между переменными - линейная!!!

Геометрическое место точек средних наблюдаемых весов при данных ростах (при изменении роста) назовем регрессионной кривой веса от роста.

Y – случайная величина, а

X не является случайной величиной

Линейная регрессия

Основные предпосылки:

- ✓ Во многих экспериментальных работах есть необходимость исследовать как изменения одной переменной влияют на изменения другой.
- ✓ Нет единственной однозначной зависимости между переменными X и Y .
- ✓ Можно заметить, что среднее значение наблюдаемой величины Y при заданной величине X изменяется монотонно с увеличением X .

Геометрическое место точек средних наблюдений Y при заданной величине X называется **регрессионной кривой**, а $Y=f(X)$ – **уравнением регрессии**.

Интересно! Термин «регрессия» был введен Френсисом Гальтоном

Метод наименьших квадратов Гаусс К. (1809 г.), Марков А. (1900 г.)

Рассмотрим важный случай: зависимость строго линейная или когда она линейная лишь для средних значений.

При заданных значениях X среднее значение Y от параметров β_0 и β_1 .

Таким образом можно оценить эти параметры

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$$

- Предсказанное значение Y для данного значения X

$$Y = \beta_0 + \beta_1 X + \varepsilon, \quad \beta_0, \beta_1 \in \mathbb{R} \quad (1)$$

ε – добавка, при учете которой любой Y не попадает на линию регрессии.

Данную величину можно интерпретировать как ошибку.

Пусть имеется множество из n наблюдений

$$(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$$

$$Y_k = \beta_0 + \beta_1 X_k + \varepsilon_k, \quad k = 1, \dots, n$$


$$\hat{\beta}_1 = \frac{\sum_{k=1}^n (X_k - \bar{X})(Y_k - \bar{Y})}{\sum_{k=1}^n (X_k - \bar{X})^2}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Пример 1: задача регрессии для выпарного аппарата

Y – количество пара в фунтах;


X – среднемесячная температура воздуха в градусах Фаренгейта.



Номер опыта	1	2	3	4	5	6	7	8	9
Y	10,98	11,13	12,51	8,4	9,27	8,73	6,36	8,5	7,82
X	35,3	29,7	30,8	58,8	61,4	71,3	74,4	76,7	70,7

Номер опыта	10	11	12	13	14	15	16	17
Y	9,14	8,24	12,19	11,88	9,57	10,94	9,58	10,09
X	57,5	46,4	28,9	28,1	39,1	46,8	48,5	59,3

Номер опыта	18	19	20	21	22	23	24	25
Y	8,11	6,83	8,88	7,68	8,47	8,86	10,36	11,08
X	70	70	74,5	72,1	58,1	44,6	33,4	28,6



$$\bar{y} = 235/25 = 9,424$$

$$\bar{x} = 1315/25 = 52,60$$

$$\hat{\beta}_1 = -0,079829$$

$$\begin{aligned}\hat{y} &= 9,4240 - 0,079828(X - 52,60) = \\ &= 13,623005 - 0,079829X\end{aligned}$$

Многомерная линейная регрессия

Пример 2: продолжение примера 1

Рассмотрим случай, когда у нас 2-е независимые переменные, т. е. добавим к модели еще один фактор:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

Y – количество пара, расходуемого в месяц;

X_1 – среднемесячная температура воздуха;

X_2 – число рабочих дней в месяце.

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

Номер опыта	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Y	10,98	11,13	12,51	8,4	9,27	8,73	6,36	8,5	7,82	9,14	8,24	12,19	11,88	9,57	10,94
	35,3	29,7	30,8	58,8	61,4	71,3	74,4	76,7	70,7	57,5	46,4	28,9	28,1	39,1	46,8
	20	20	23	20	21	22	11	23	21	20	20	21	21	19	23


Номер опыта	16	17	18	19	20	21	22	23	24	25
Y	9,58	10,09	8,11	6,83	8,88	7,68	8,47	8,86	10,36	11,08
	48,5	59,3	70	70	74,5	72,1	58,1	44,6	33,4	28,6
	20	22	22	11	23	20	21	20	20	22

$$Y = \begin{pmatrix} 10,98 \\ 11,13 \\ 12,51 \\ 8,4 \\ \vdots \\ 10,36 \\ 11,08 \end{pmatrix} X = \begin{pmatrix} 1 & 35,3 & 20 \\ 1 & 29,7 & 20 \\ 1 & 30,8 & 23 \\ 1 & 58,8 & 20 \\ \vdots & \vdots & \vdots \\ 1 & 33,4 & 20 \\ 1 & 28,6 & 22 \end{pmatrix} \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \\ \varepsilon_4 \\ \vdots \\ \varepsilon_{24} \\ \varepsilon_{25} \end{pmatrix} \quad \hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix}$$


$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \left\{ \begin{pmatrix} 1 & 35,3 & 20 \\ 1 & 29,7 & 20 \\ 1 & 30,8 & 23 \\ 1 & 58,8 & 20 \\ \vdots & \vdots & \vdots \\ 1 & 33,4 & 20 \\ 1 & 28,6 & 22 \end{pmatrix}^T \times \begin{pmatrix} 1 & 35,3 & 20 \\ 1 & 29,7 & 20 \\ 1 & 30,8 & 23 \\ 1 & 58,8 & 20 \\ \vdots & \vdots & \vdots \\ 1 & 33,4 & 20 \\ 1 & 28,6 & 22 \end{pmatrix} \right\}^{-1} \times \begin{pmatrix} 1 & 35,3 & 20 \\ 1 & 29,7 & 20 \\ 1 & 30,8 & 23 \\ 1 & 58,8 & 20 \\ \vdots & \vdots & \vdots \\ 1 & 33,4 & 20 \\ 1 & 28,6 & 22 \end{pmatrix}^T \times \begin{pmatrix} 10,98 \\ 11,13 \\ 12,51 \\ 8,4 \\ \vdots \\ 10,36 \\ 11,08 \end{pmatrix} =$$

$$\begin{pmatrix} 9,1266 \\ -0,0724 \\ 0,2029 \end{pmatrix}$$

Точечная диаграмма



$\hat{Y} = 9,1266 - 0,0724X_1 + 0,2029X_2$ –
предсказанное значение Y для заданных
 X_1 и X_2



Более сложные модели линейной регрессии

Более сложные модели линейной регрессии

Общий вид линейной модели

$$Y = \beta_0 Z_0 + \beta_1 Z_1 + \beta_2 Z_2 + \dots + \beta_p Z_p + \varepsilon$$

$$Z_0=1, Z_j = Z_j(X_1, X_2, \dots, X_k), j=1, \dots, p$$

Полиномиальные модели различных порядков

Модели первого порядка



1. Если $p = 1$ и $Z_1 = X$, то имеем простую модель первого порядка с одной независимой переменной.

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

2. Если $p = k$ и $Z_j = X_j$, то имеем модель первого порядка с k независимыми переменными.

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \varepsilon$$

Модели второго порядка



1. Если $p = 2$ и $Z_1 = X$, $Z_2 = X^2$ то имеем модель второго порядка с одной независимой переменной.

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \varepsilon$$

2. Если $p = 5$ и $Z_1 = X_1$, $Z_2 = X_2$, $Z_3 = X_1^2$, $Z_4 = X_2^2$ и $Z_5 = X_1 X_2$, то имеем модель второго порядка с двумя независимыми переменными.

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1^2 + \\ + \beta_4 X_2^2 + \beta_5 X_1 X_2 + \varepsilon$$

Логистическая кривая

Историческая справка: терминология «логистическая регрессия» берет свое начало от логистического уравнения (уравнение Ферхюльста).

$$\dot{y} = a y \left(1 - \frac{y}{b} \right), \quad y \geq 0.$$

Данное уравнение описывает изменение численности популяции.

y – численность популяции


Параметры уравнения:

$a > 0$ – характеризует скорость роста.


$b > 0$ – максимально возможная численность популяции.

$$y(t) = \frac{by_0 \exp(at)}{b + y_0(\exp(at) - 1)}$$

$b=1, y_0=1/2, a=1,$ $\sigma(x) = \frac{\exp(x)}{1 + \exp(x)} = \frac{1}{1 + \exp(-x)}$ - сигмоида




1. $\lim_{x \rightarrow +\infty} \sigma(x) = 1$
 $\lim_{x \rightarrow -\infty} \sigma(x) = 0$
2. Точка перегиба $\left(0, \frac{1}{2}\right)$
3. $\sigma(-x) = 1 - \sigma(x)$



Пусть $\sigma_{\alpha}(x) = \sigma(\alpha x)$.

Тогда в зависимости от α логистическая кривая ведет себя как показано на рисунке.



При $\alpha \rightarrow \infty$ логистическая кривая вырождается в функцию Хевисайда.

$$\eta(x) = \begin{cases} 1, & x \geq 0, \\ 0, & x < 0 \end{cases}$$



КЛАСТЕРИЗАЦИЯ

Кластеризация предназначена для разбиения совокупности объектов на однородные группы (кластеры или классы). Если данные выборки представить как точки в признаковом пространстве, то задача кластеризации сводится к определению "сгущений точек".

Цель кластеризации - поиск существующих структур.


Переводится понятие кластер (cluster) как "скопление", "гроздь".

Кластер можно охарактеризовать как группу объектов, имеющих общие свойства.

Характеристиками кластера можно назвать два **признака**:

- внутренняя однородность;
- внешняя изолированность.

Наибольшее применение кластеризация первоначально получила в таких науках как биология, антропология, психология. Для решения экономических задач кластеризация длительное время мало использовалась из-за специфики экономических данных и явлений.



Термин кластерный анализ, впервые введенный Трионом (Tryon) в 1939 году, включает в себя более 100 различных алгоритмов.

№ примера	признак X	признак Y
1	27	19
2	11	46
3	25	15
4	36	27
5	35	25
6	10	43
7	11	44
....	...	...





Диаграмма рассеивания переменных X и Y

Критерием для определения схожести и различия кластеров является расстояние между точками на диаграмме рассеивания. Это сходство можно "измерить", оно равно расстоянию между точками на графике. Способов определения меры расстояния между кластерами, называемой еще мерой близости, существует несколько. Наиболее распространенный способ - вычисление евклидова расстояния между двумя точками i и j на плоскости, когда известны их координаты X и Y :

$$D_{ij} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}$$

$$D = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2 + (z_1 - z_2)^2}$$




Расстояние между двумя точками в пространстве трех измерений


- Спорный объект - это объект, который по мере сходства может быть отнесен к нескольким кластерам. Размер кластера может быть определен либо по радиусу кластера, либо по среднеквадратичному отклонению объектов для этого кластера. Объект относится к кластеру, если расстояние от объекта до центра кластера меньше радиуса кластера. Если это условие выполняется для двух и более кластеров, объект является спорным.
- Неоднозначность данной задачи может быть устранена экспертом или аналитиком.

Алгоритм k-средних (k-means)

- Наиболее распространен среди неиерархических методов алгоритм k-средних, также называемый быстрым кластерным анализом. Полное описание алгоритма можно найти в работе Хартигана и Вонга (Hartigan and Wong, 1978). В отличие от иерархических методов, которые не требуют предварительных предположений относительно числа кластеров, для возможности использования этого метода необходимо иметь гипотезу о наиболее вероятном количестве кластеров.
- Основной тип задач, которые решает алгоритм k-средних, - наличие предположений (гипотез) относительно числа кластеров, при этом они должны быть различны настолько, насколько это возможно. Выбор числа k может базироваться на результатах предшествующих исследований, теоретических соображениях или интуиции.
- Общая идея алгоритма: заданное фиксированное число k кластеров наблюдения сопоставляются кластерам так, что средние в кластере (для всех переменных) максимально возможно отличаются друг от друга.




K=3



$$(x', y') = \left(\frac{x_1 + x_2 + x_3}{3}, \frac{y_1 + y_2 + y_3}{3} \right)$$

$$(x'', y'') = \left(\frac{x_1 + \dots + x_{11}}{11}, \frac{y_1 + \dots + y_{11}}{11} \right)$$

$$(x''', y''') = \left(\frac{x_1 + \dots + x_5}{5}, \frac{y_1 + \dots + y_5}{5} \right)$$



$$WCSS = \sum_{C_k}^{C_n} \left(\sum_{d_i \in C_i}^{d_m} \text{distance}(d_i, C_k)^2 \right)$$

Алгоритм k-средних (k-means)

1. Первоначальное распределение объектов по кластерам. Выбирается число k , и на первом шаге эти точки считаются "центрами" кластеров. Каждому кластеру соответствует один центр. Выбор начальных центроидов может осуществляться следующим образом:
 - выбор k -наблюдений для максимизации начального расстояния;
 - случайный выбор k -наблюдений;
 - выбор первых k -наблюдений.
2. Итеративный процесс. Вычисляются центры кластеров, которыми затем и далее считаются координатные средние кластеров. Объекты опять перераспределяются. Процесс вычисления центров и перераспределения объектов продолжается до тех пор, пока не выполнено одно из условий:
 - кластерные центры стабилизировались, т.е. все наблюдения принадлежат кластеру, которому принадлежали до текущей итерации;
 - число итераций равно максимальному числу итераций.

Выбор числа кластеров является сложным вопросом. Если нет предположений относительно этого числа, рекомендуют создать 2 кластера, затем 3, 4, 5 и т.д., сравнивая полученные результаты.

Проверка качества кластеризации



После получения результатов кластерного анализа методом k-средних следует проверить правильность кластеризации (т.е. оценить, насколько кластеры отличаются друг от друга). Для этого рассчитываются средние значения для каждого кластера. При хорошей кластеризации должны быть получены сильно отличающиеся средние для всех измерений или хотя бы большей их части.

Достоинства алгоритма k-средних:


- простота использования;
- быстрота использования;
- понятность и прозрачность алгоритма.

Недостатки алгоритма k-средних:

- алгоритм слишком чувствителен к выбросам, которые могут искажать среднее.
- алгоритм может медленно работать на больших базах данных.



K=2



K=3

Пример кластеризации на языке python

 K-means.ipynb ☆

Файл Изменить Вид Вставка Среда выполнения Инструменты Справка [Последнее изменение: 27 апреля](#)

+ Код + Текст

 `pip install scikit-learn`


 Requirement already satisfied: scikit-learn in /usr/local/lib/python3.10/dist-packages (1.2.2)
Requirement already satisfied: numpy>=1.17.3 in /usr/local/lib/python3.10/dist-packages (from scikit-learn) (1.25.2)
Requirement already satisfied: scipy>=1.3.2 in /usr/local/lib/python3.10/dist-packages (from scikit-learn) (1.11.4)
Requirement already satisfied: joblib>=1.1.1 in /usr/local/lib/python3.10/dist-packages (from scikit-learn) (1.4.0)
Requirement already satisfied: threadpoolctl>=2.0.0 in /usr/local/lib/python3.10/dist-packages (from scikit-learn) (3.4.0)

```
[ ] import sklearn
import numpy as np
import matplotlib.pyplot as plt
```

```
[ ] from sklearn.cluster import KMeans
```

 `X=np.array([[0,0],
[1,0],
[0,1],
[1,1],
[2,1],
[1,2],
[2,2],
[3,2],
[6,6],
[7,6],
[8,6],
[6,7],
[7,7]])`

Пример кластеризации на языке python



Пример кластеризации на языке python

```
[ ] # Печать центров кластеров  
k_meancntr=k_means.cluster_centers_  
print(k_means.cluster_centers_)
```

```
⇒ [[6.8  6.4  ]  
   [1.25 1.125]]
```


```
[ ] # вывод меток классов кластеров  
print(k_means.labels_)
```

```
⇒ [1 1 1 1 1 1 1 1 0 0 0 0 0]
```

Пример кластеризации на языке python

```
plt.scatter(X[:,0], X[:,1], c=k_means.labels_, marker='^', cmap='rainbow')  
plt.scatter(k_means.cluster_centers_[:,0], k_means.cluster_centers_[:,1], marker='^', color='black')
```

<matplotlib.collections.PathCollection at 0x7cc5b4cc3c40>




Пример кластеризации на языке python

```
▶ n_inertia = []

for i in range(1, 11):
    km = KMeans(n_clusters=i).fit(X)
    n_inertia.append(km.inertia_)

fig, ax = plt.subplots()
sns.lineplot(x=np.arange(1, 11), y=n_inertia, ax=ax)
ax.set_title('Метод локтя')
ax.set_xlabel('Количество кластеров')
ax.set_ylabel('Инерция кластеризации')
plt.show()
```



СПАСИБО ЗА ВНИМАНИЕ!